

CMS y CountSketch en Ventana Deslizante

Tarea 1 — Tópicos en Grandes Volúmenes de Datos

Lucas Morales Oyanedel

1 de octubre de 2026

Objetivo del Sistema

Monitorear tráfico de red en tiempo real mediante memoria sublineal utilizando una **ventana deslizante** $W = 60$ s con paso $\delta = 10$ s.

Dataset de Evaluación

- **Traza real:** MAWI samplepoint-F (2018-12-03 14:00 JST).
- **Ataques inyectados:** Sintéticos (semilla 42), activos en $t \in [300, 330]$ s.

Caracterización de Ataques

DDoS Attack:

- 10 000 pps, 4 000 fuentes.
- Clave de agrupación: dst.

Scan Attack:

- 8 000 pps, 60 000 destinos.
- Clave de agrupación: src.

Mantenimiento de Ventana por Linealidad

Propiedad de Anillo de Sketches

La ventana completa se compone de la suma de m subventanas discretas:

$$A_{j+1} = A_j - S_{j-m+1} + S_{j+1}$$

Ventajas Algorítmicas

- **Operaciones por paso:** Se expira S_{j-m+1} y se incorpora S_{j+1} .
- **Actualizaciones totales:** $2 \cdot d \cdot w$ celdas afectadas.
- **Complejidad:** $\mathcal{O}(d \cdot w)$ por rotación.
- **Costo independiente** del flujo de paquetes dentro de la ventana.

Alineación y Precarga

- Subventana calculada mediante $\lceil (ts - t_0)/p \rceil$.
- Alineación por techo (`ceil`) evita el descalce temporal al expirar los paquetes.
- Precarga completa del anillo en el intervalo $(t_0, t_0 + W]$.

Estimadores Implementados

Sketch	Fórmula Estimadora
CMS	$\text{máx}(0, \text{mín}_j C[j][h_j(k)])$
CS	$\text{mediana}_j (s_j(k) \cdot C[j][h_j(k)])$
CMS-med	$\text{mediana}_j (C[j][h_j(k)])$

Umbral Heavy Hitter


$$T_j = \lceil \varphi \cdot N_j \rceil$$

N_j mantenido exactamente con un anillo escalar paralelo.

Decisiones Teóricas / C++

- **Clave Única de 128-bits:** unsigned __int128 para procesar src, dst y 5tuple sin duplicar código.
- **Hashing Determinista:** SplitMix64 para cálculo de buckets $h_r(k)$ y signos $s_r(k) \in \{-1, +1\}$.
- **Validación de N_j :** Verificado al 100 % contra la herramienta ground truth exact_hh.


Frecuencia Absoluta en DDoS (freq_ddos.png)



Observaciones Experimentales

- **Sesgo en CMS:** Para $w = 256$, la sobreestimación por colisiones es severa.
- **Insegadez en CS:** Las funciones de signo cancelan ruido; con $w = 4096$ convergen exactamente al Ground Truth.
- **Perfil Temporal:** Muestra la rampa de entrada (60 s), la meseta de impacto y el descenso por expiración.


Frecuencia Absoluta en Scan (freq_scan.png)



Comportamiento ante Scan

- Clave evaluada: src (identifica al escaneador).
- **Error Relativo:** En la ventana de ataque ($t \in [300, 330]$), la tasa de error disminuye drásticamente debido a la dominancia del tráfico anómalo.
- CS alcanza un error relativo menor a 10^{-3} en configuraciones de $w \geq 1024$.

Variación de Frecuencia Δf — DDoS (delta_ddos.png)




Monitoreo de Cambio

$$\Delta f_j(x) = f_j(x) - f_{j-1}(x)$$

- **Pico Positivo ($t = 300$ s):** Firma clara de inicio del ataque.
- **Pico Negativo ($t = 360$ s):** Salida del volumen del ataque tras vencer la ventana W .
- **Panel Inferior:** Demuestra la superioridad de CountSketch en la reducción del error absoluto.

Variación de Frecuencia Δf — Scan (delta_scan.png)



Firmas de Transición

- $\Delta f \approx 0$ durante la estabilidad de fondo o durante el transcurso estable del ataque.
- **Respuesta al Inicio/Fin:** Detecta transiciones instantáneas a diferencia de $f(x)$ acumulado.
- **Comportamiento de CMS-mediana:** Presenta fluctuaciones en zonas limítrofes por pérdida de garantías de no negatividad.

Preguntas Clave del Estudio (1/2)

1. ¿Efecto de reducir el ancho w ?

Aumentan las colisiones en los buckets.

- **CMS:** Genera sobreestimación monótona y creciente ($\hat{f} \geq f$).
- **CS:** Mantiene el carácter insesgado $\mathbb{E}[\hat{f}] = f$, pero incrementa sensiblemente la varianza del estimador.

2. ¿Por qué se eligen distintas claves para DDoS y Scan?

- **DDoS:** Patrón *Many-to-One*. Concentra flujo en el destino, requiriendo agregación por clave `dst`.
- **Scan:** Patrón *One-to-Many*. Concentra flujo en el origen, requiriendo agregación por clave `src`.

3. ¿Valor agregado de la métrica $\Delta f_j(x)$?

Permite detectar la **tasa neta de cambio**. Aporta firmas instantáneas de la entrada (+pico) y

CountSketch en Diferencias

- Soporta algebraicamente deltas positivos y negativos gracias a las funciones de signo $s(k) \in \{-1, +1\}$.
- La resta entre subventanas no invalida la mediana de los productos como estimador no sesgado.
- **Conserva garantías teóricas** al estimar Δf .

CMS con Mediana (CMS-med)

- CMS tradicional utiliza el operador mín, requiriendo estrictamente datos no negativos ($f \geq 0$).
- Al evaluar diferencias Δf , aparecen términos negativos donde el operador mín falla.
- Reemplazar por la mediana funciona únicamente como una **heurística**, perdiendo las garantías teóricas sobre el error.

Conclusiones Principales

- ➊ **Eficiencia Operativa:** La estructura de anillo en combinación con la propiedad de linealidad permite mantener sketches en ventanas deslizantes con un costo computacional acotado a $\mathcal{O}(d \cdot w)$.
- ➋ **Precisión de Estimación:** CountSketch resulta ampliamente superior para el cálculo de variaciones Δf y evita el sesgo acumulativo presentado por CMS en tablas de ancho acotado.
- ➌ **Semántica de Agregación:** Seleccionar la clave correcta (dst vs src) es indispensable para visibilizar y concentrar las firmas anómalas de cada ataque.
- ➍ **Métrica Diferencial:** Δf provee información temporal para la detección temprana y delimitación precisa de ataques de red.